PDF ingestion

การอ่านเอกสาร PDF

เก็บชื่อไฟล์และเลขหน้าไว้กับข้อความทุกส่วน

PDF ingestion extracts the text layer separately from each physical page. Each extracted record keeps the source filename and a one-based page number. Keeping pages separate lets a search result point back to its evidence. Scanned images without a text layer need OCR before this pipeline can index them.

Chunking and overlap

การแบ่งข้อความและ overlap

แบ่งข้อความเป็นชิ้นและให้ขอบเขตซ้อนกัน

Chunking divides page text into smaller sections before embedding. An overlap repeats a short suffix at the beginning of the next section so a sentence near a boundary retains context. The overlap must be nonnegative and smaller than the chunk size. Chunks in this demonstration never cross page boundaries.

Embeddings and FAISS

เวกเตอร์และ FAISS

แปลงข้อความเป็นเวกเตอร์แล้วสร้างดัชนีค้นหา

An embedding model represents each text chunk as a numeric vector. Similar meanings tend to produce nearby vectors. FAISS stores these vectors and searches them efficiently. When vectors are normalized to unit length, inner product equals cosine similarity. Document and query vectors must come from the same embedding model.

Semantic retrieval

การค้นหาความหมาย

คืนข้อความทีเกียวข้องพร้อมชือไฟล์และเลขหน้า

Semantic retrieval embeds the user's question and compares it with indexed document vectors. Top-k is the number of ranked chunks returned, not a confidence threshold. A retrieved chunk should carry its filename and physical page number so the reader can inspect the original evidence. A high similarity score does not prove that an answer is correct.